INSIDE AIRBNB · SEPTEMBRE 2026 · RAPPORT DÉTAILLÉ

Le juste prix d'un logement Airbnb dans 15 villes

Un projet de machine learning de bout en bout : méthodes, résultats et valeur métier

485 128	15	21,7 M	0,815
annonces	villes	avis	R^2 sur le test

Données : Inside Airbnb (CC BY 4.0) · Code, notebook et modèle : voir le dossier du projet

Sommaire

	Section
1	Résumé exécutif
2	Contexte, problématique et parties prenantes
3	Données et audit
4	Analyse exploratoire
5	Nettoyage
6	Construction des variables
7	Sélection de variables
8	Stratégie de validation et effet ville
9	Régression du prix
10	Intervalles de prédiction et test final
11	Classification
12	Apprentissage non supervisé
13	NLP sur les avis
14	Séries temporelles (calendrier)
15	Deep learning
16	Interprétabilité
17	Apport métier
18	Limites et éthique
19	Conclusion et recommandations
A	Glossaire
B	Reproductibilité et décisions à justifier

Comment lire ce rapport. Chaque section présente la **méthode**, puis les **résultats chiffrés**, puis ce qu'ils signifient. Tous les chiffres viennent de code exécuté (le notebook *00_projet_complet.ipynb* contient le code et les graphiques). Le jeu de test final (14,3 % des annonces, hôtes jamais vus) n'a été ouvert **qu'une seule fois**, à la fin.

1 Résumé exécutif

Question. Comment aider un hôte ou une plateforme à estimer le **prix juste** d'un logement et à repérer les **facteurs de qualité**, de manière **généralisable à plusieurs villes** ?

Données. 485 128 annonces dans 15 villes (septembre 2026), 21,7 millions d'avis, 15 calendriers de 365 jours. Le prix est un **devis pour un séjour précis** (1 à 31 nuits), manquant pour 25 % des annonces.

0,815	**27 €**	**53 %**	**90,4 %**
R^2 sur le test final	erreur absolue médiane	des annonces à ±20 % du prix	couverture de la fourchette à 90 %

Résultats principaux

- **Prix** : RMSE de 0,354 sur le log du prix, erreur absolue moyenne de **68 €** par nuit (médiane 27 €). Résultats cohérents avec la validation croisée (RMSE 0,356).
- **Fourchette de prix** à 90 % (intervalle conforme adaptatif) : 90,4 % de couverture sur le test, largeur moyenne 245 €.
- **Superhost** : ROC-AUC de 0,829 avec les seules caractéristiques du logement et de l'hôte, 0,886 avec les notes (qui recopient en partie les critères d'attribution).
- **Tranche de prix** (bas, moyen, haut dans la ville) : accuracy 0,756.
- **Ville jamais vue** : l'effet ville est massif (RMSE de 0,366 à 0,583). 72 % de l'écart vient d'un décalage de niveau de prix, **corrigeable avec quelques dizaines d'annonces** de la nouvelle ville.
- **Boosting contre réseau de neurones** : LightGBM bat le réseau dense dans chacun des 5 plis (RMSE 0,3674 contre 0,3965).

Ce que le modèle ne sait pas

Il **sous-estime les logements très chers** (la fourchette ne contient le prix réel que dans 68 % des cas pour les prix réels supérieurs à 600 €) ; il n'est **pas exploitable dans une ville nouvelle sans recalibration** ; ses « leviers » (équipements, caractéristiques) sont des **associations**, pas des causes ; le prix étudié est un prix **affiché**, pas un prix payé.

Valeur métier. Pour un hôte : un prix recommandé et une fourchette honnête plutôt qu'une intuition. Pour une plateforme : un repérage des annonces très écartées du prix attendu, des annonces fantômes et des points de friction des voyageurs. Pour une ville : une mesure de la concentration des hôtes. Pour un déploiement : une procédure de recalibrage chiffrée.

2 Contexte, problématique et parties prenantes

Inside Airbnb publie, ville par ville, les annonces, les avis et les calendriers visibles sur la plateforme. Les données sont brutes : prix en texte et en plusieurs devises, équipements en listes JSON, valeurs manquantes et extrêmes, avis multilingues. Le projet couvre l'ensemble de la chaîne : audit, nettoyage, variables, sélection, validation, modèles de régression et de classification, apprentissage non supervisé, NLP, séries temporelles, deep learning, interprétabilité et apport métier.

Acteur	Besoin	Ce que le projet apporte
Hôtes	Fixer un prix cohérent avec le marché, avec une marge d'incertitude	Prix recommandé et fourchette à 90 % ; équipements associés à un prix plus élevé ; effets de la durée du séjour et des jours de la semaine
Plateforme	Qualité, confiance, annonces fantômes	Repérage des annonces très écartées du prix attendu, des annonces fantômes ; points de friction des avis ; profil des Superhosts
Investisseurs et villes	Comprendre le marché, la saisonnalité, la régulation	Quartiers sous ou sur-évalués ; concentration des hôtes ; calendrier de la demande ; procédure pour une ville nouvelle

Trois règles de rigueur

- **Aucune fuite de données** : tout ce qui apprend sur les données (imputation, encodage, sélection de variables, seuils de nettoyage, TF-IDF, LDA) est ajusté sur le train, dans des Pipelines sklearn, y compris dans la validation croisée.
- **Un hôte n'est jamais à la fois dans le train et dans le test** : il possède souvent plusieurs annonces presque identiques. Toutes les validations sont groupées par hôte.
- **Aucun chiffre inventé** : tout résultat vient de code exécuté, graine fixée à 42, versions figées ; tout échantillonnage est signalé.

3 Données et audit

Source	Contenu	Volume
listings	Caractéristiques des annonces (94 colonnes), hôte, quartier, notes, disponibilité	485 128 annonces, 253 996 hôtes
reviews	Texte et date de chaque avis	21 726 192 avis
calendar	Disponibilité des 365 prochaines nuits, par annonce (sans prix)	15 fichiers
Taux de change	Taux de référence de la BCE, à la date de collecte de chaque ville	6 devises (GBP, USD, MXN, AUD, JPY, CAD)

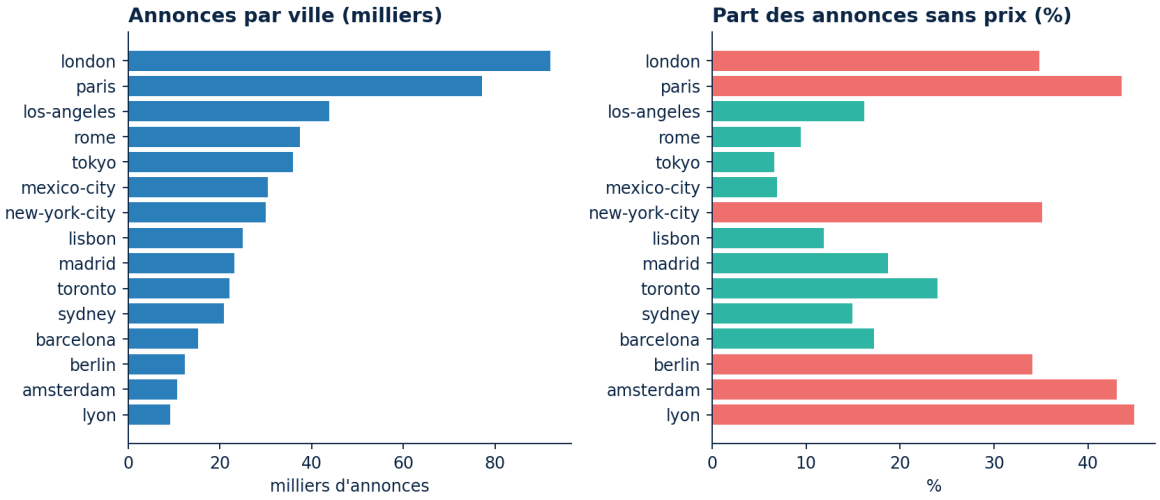


Figure 1. Taille des 15 villes et part d'annonces sans prix (rouge : plus de 30 %).

Ce que révèle l'audit

- **Une seule date de collecte par ville** (14 au 25 septembre 2026) : on observe un instantané, pas une histoire.
- **13 colonnes sont vides dans les 15 villes** (par exemple l'ancienneté de l'hôte, le taux de réponse, la réservation instantanée) : le format publié a changé.
- **Le prix manque pour 25 % des annonces** (de 6,6 % à Tokyo à 44,9 % à Lyon). Ce manque est lié à l'indisponibilité : 77 % des annonces sans prix sont indisponibles toute l'année, contre 5 % parmi celles qui ont un prix. Le modèle ne verra donc que des annonces réservables : c'est un **biais de sélection**.
- **Le « $ » du prix brut est trompeur** : pour Paris, la devise réelle est l'euro (elle est donnée par le devis). Se fier au symbole aurait faussé tous les prix.
- **485 128 annonces pour 253 996 hôtes** : un hôte possède en moyenne presque deux annonces, ce qui impose le découpage par hôte.

4 Analyse exploratoire

L'exploration porte sur les annonces du train. Les prix sont convertis en euros (section 5). Voici les constats qui ont orienté la suite.

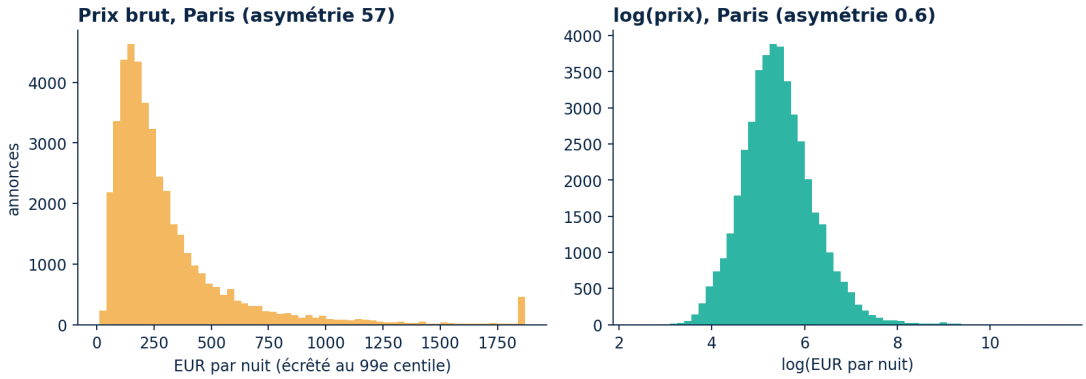


Figure 2. Le prix brut est très asymétrique ; son logarithme est presque symétrique (Paris). La cible du modèle est donc le log du prix : les erreurs deviennent relatives.

Constat	Chiffre
Asymétrie du prix à Paris, brut contre log	57 contre 0,6
Prix relatif à la médiane de la ville : logement entier, chambre privée, chambre partagée	×1,16, ×0,54, ×0,22
Variables les plus liées au log du prix (Spearman)	capacité +0,47 ; lits +0,42 ; chambres +0,34 ; séjour minimum −0,24
Paris : prix médian par arrondissement (train)	de 146 € (Ménilmontant) à 339 € (Élysée), soit ×2,3
Distance au centre et prix	liés négativement dans 14 villes sur 15
Annonces d'hôtes avec 5 annonces ou plus	38 % des annonces (de 7 % à Amsterdam à 74 % à Tokyo)
Note globale	médiane 4,84 ; 87 % des notes ≥ 4,5 (forte positivité)
Annonces fantômes probables (indisponibles 365 jours et aucun avis sur 12 mois)	15 % (de 1 % à Tokyo à 33 % à Lyon)

Pièges de fuite repérés

Variable	Problème	Décision
estimated_revenue_l365d	Vaut exactement prix × occupation estimée (ratio 1,00 pour 100 % des annonces concernées)	Exclue de la régression
price_quote_*	Copie du prix lui-même (corrélation 1,00)	Supprimée
Disponibilités, avis récents	Conséquences du prix : une annonce chère se réserve moins	Exclues du jeu de référence
Notes et activité des avis (pour le Superhost)	Critères d'attribution du statut et conséquences de celui-ci	Testées avec et sans (section 11)

5 Nettoyage

Le principe est qu'**aucune ligne n'est supprimée** : les cas douteux sont **signalés** par des indicateurs et ce sont les modèles qui filtrent, ce qui permet toujours de mesurer ce que le filtrage change. Chaque choix est journalisé (nombre de lignes concernées, raison). Tous les seuils sont appris sur le train.

Étape	Volume	Pourquoi
Conversion des prix en euros	362 593 prix	Taux BCE du dernier jour ouvré avant la date de collecte de chaque ville. Les 122 535 annonces sans prix restent sans prix (aucun prix récupérable)
Colonnes vides ou inutiles	13 vides + 18 supprimées	URL, identifiants techniques, copie du prix, nom de l'hôte (RGPD) ; les textes sont conservés à part pour le NLP
Équipements	32 755 libellés → 164 colonnes	Normalisation (minuscules, détails de marque retirés) ; seuil de 1 % des annonces du train ; le reste est compté à part
Salles de bain	484 570 lues	Texte converti en nombre (demi-salle de bain = 0,5) et indicateur « partagée »
Valeurs sentinelles	125	maximum_nights à 2 147 483 647 plafonné à 1 125
Annonces incohérentes	1 548	Capacité élevée sans couchage, lits ou chambres hors de proportion : signalées, exclues de l'entraînement
Quasi-doublons	24 729	Même hôte, mêmes coordonnées et caractéristiques : signalés, non supprimés (souvent des unités d'un même immeuble)
Prix extrêmes	651 (0,18 %)	Hors de Q1 − 3×IQR et Q3 + 3×IQR du log du prix, par ville (train) : signalés, exclus de l'entraînement seulement
Jeu de test	69 304 annonces (14,3 %)	Tiré par hôte, stratifié par ville, mis sous scellés dès cette étape

Impact de la règle des prix extrêmes. Un LightGBM de référence, validé sur 20 % des hôtes du train, passe d'un RMSE de 0,4654 à 0,4642 (évalué hors extrêmes) en retirant ces 0,18 % d'annonces de l'entraînement : l'effet est faible mais favorable. On exclut donc ces annonces de l'entraînement mais on les garde dans l'évaluation, pour rester honnête sur ce que verrait un utilisateur.

6 Construction des variables

Deux familles de transformations : **sans apprentissage** (formules par ligne, donc sans risque de fuite) stockées dans une table de 275 colonnes, et **avec apprentissage** (imputation, encodage, mise à l'échelle) placées dans un Pipeline ajusté sur le train de chaque pli.

Famille	Variables	Idée
Logement	capacité, chambres, lits, salles de bain, type, ratios (lits par personne, personnes par chambre)	Les ratios décrivent mieux la densité d'occupation que les comptages
Localisation	latitude, longitude, distance au centre, quartier, ville	Le quartier est très discriminant mais compte 1 294 couples ville-quartier
Hôte	ancienneté, hôte professionnel (≥ 5 annonces), part de logements entiers, vérification	Un hôte expérimenté ou professionnel fixe d'autres prix
Équipements	164 indicateurs et leur nombre	Confort et services
Texte	longueur de la description et du titre	Soin apporté à l'annonce
Contexte du devis	durée du séjour, délai avant l'arrivée, mois, week-end, séjour mensuel	Le prix est un devis pour un séjour précis, pas un prix catalogue

Prétraitement dans le Pipeline

- **Numériques** : imputation par la médiane de la ville et indicateurs de manquant ; standardisation seulement pour les modèles qui en ont besoin.
- **Catégories à faible cardinalité** (type de logement, type de propriété, ville) : one-hot, modalités de moins de 1 % regroupées.
- **Quartier** : target encoding avec validation croisée interne à 5 plis. La corrélation entre l'encodage et la cible est de 0,545 sur le train, 0,548 sur des hôtes jamais vus et 0,553 pour un encodage naïf (optimiste) : pas de fuite visible.

Le contexte du devis change le résultat. Ajouter la durée du séjour, le délai et la saisonnalité fait passer le RMSE de LightGBM de 0,396 à 0,374. Le prix affiché n'est pas un prix catalogue : les séjours longs bénéficient de remises (voir la section 16 : −35 % de prix par nuit entre 1 et 90 nuits).

Non créées : la surface par personne (aucune surface dans les données) et la langue de la description (99,4 % détectée en anglais, texte traduit à la source : aucune variance).

7 Sélection de variables

Seize méthodes sont comparées sur la tâche de référence (régression du log du prix) : **filtres** (variance, corrélation, information mutuelle, ANOVA, chi²), **wrappers** (RFECV, SFS), **méthodes embarquées** (Lasso, Elastic Net, importance des arbres), **méthodes agnostiques** (permutation, SHAP), **VIF**, et la **PCA** comme alternative par transformation. Protocole : 60 000 annonces du train, 5 plis groupés par hôte ; dans chaque pli, prétraitement et sélection sont ajustés sur le train du pli ; évaluation par LightGBM (200 arbres). La permutation est calculée sur un split interne, jamais sur le pli de validation.

Méthode	Variables	RMSE (LightGBM)
Toutes les variables	259	0,3854
60 variables aléatoires	60	0,4812
Corrélation (k=60)	60	0,4293
Information mutuelle (k=60)	60	0,3966
Chi² (k=60)	60	0,4796
RFECV (Ridge)	131	0,3875
SFS avant (25 parmi 80)	25	0,4313
Lasso	226	0,3876
LightGBM : gain (95 % cumulé)	39	0,3912
Random Forest : impureté	79	0,3884
Permutation	143	0,3858
SHAP (95 % cumulé)	81	0,3876
VIF (seuil 10)	236	0,3879
PCA (95 % de variance)	191	0,4507

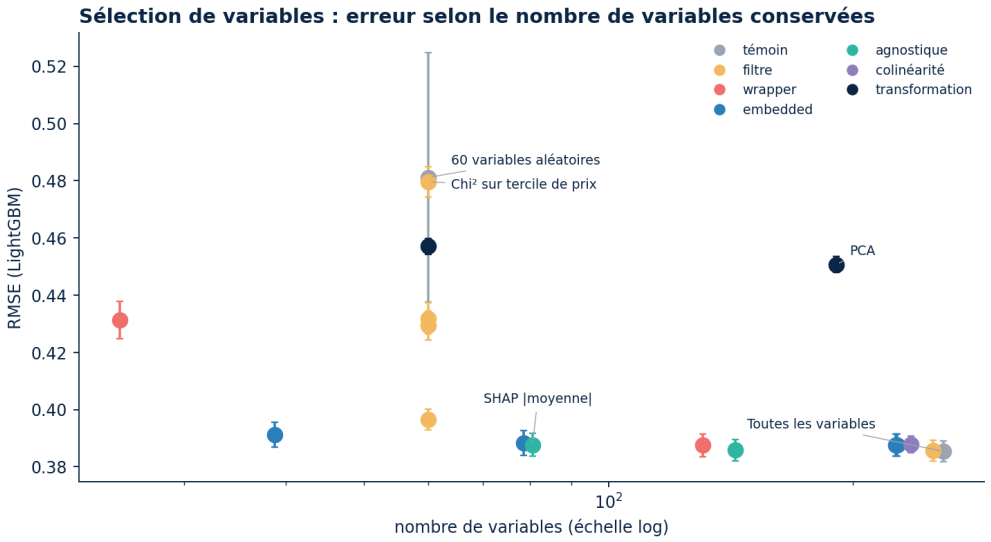


Figure 3. Erreur de validation selon le nombre de variables conservées (barres : écart-type entre plis).

Ce qu'on en retient

- **Aucune méthode ne bat « toutes les variables »** (0,3854) : LightGBM tolère bien les variables peu utiles. L'intérêt de la sélection est la simplicité et l'interprétabilité. 60 variables tirées au hasard donnent 0,4812 : la sélection a un sens.
- **Meilleur compromis** : SHAP garde 81 variables sur 259 pour 0,3876 (+0,002).

- **Les filtres univariés sont les moins fiables** (chi² proche du hasard) : ils ignorent interactions et redondance. L'information mutuelle fait mieux car elle capte les relations non linéaires.
- **Le biais des importances d'arbres** : l'impureté d'une forêt surévalue les variables continues à forte cardinalité (la longueur de la description est au rang 29 en impureté, 70 en permutation) et sous-évalue des indicateurs utiles comme la climatisation (rang 43 contre 20). Permutation et SHAP, calculées hors échantillon d'entraînement, sont plus fiables.
- **La PCA** est nettement moins bonne que la sélection (0,451) et détruit l'interprétabilité.

8 Stratégie de validation et effet ville

Définie avant toute exploration pour ne pas être influencée par le test. Trois schémas sont comparés, entraînés sur les 309 412 annonces du train (jeu de régression).

Schéma	Principe	Question posée
A	5 plis, stratifiés par ville, groupés par hôte	Quelle performance dans des villes connues ?
B	Leave-one-city-out : 14 villes pour entraîner, la 15e pour tester	Quelle performance dans une ville jamais vue ?
C	Entraînement sur les séjours de septembre 2026, test sur des hôtes disjoints avec séjours à partir d'octobre	Quelle performance sur d'autres dates de séjour ?

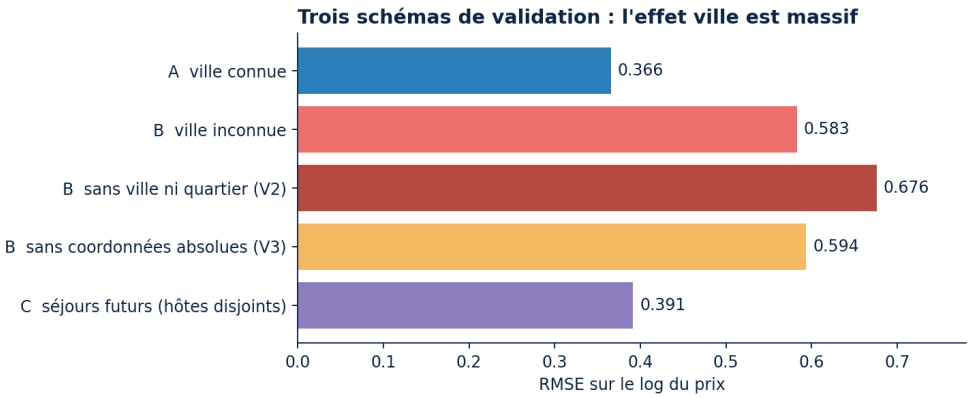


Figure 4. RMSE selon le schéma de validation (V2 : sans identifiants de ville et de quartier ; V3 : sans non plus latitude et longitude absolues).

- **L'effet ville est massif** : le RMSE passe de 0,366 (ville connue) à 0,583 (ville jamais vue), le R^2 de 0,80 à 0,48, l'erreur moyenne de 68 € à 105 €.
- **72 % de l'écart quadratique vient d'un décalage de niveau de prix** de la ville ; 28 % seulement d'une moins bonne hiérarchie interne. Le modèle classe bien les annonces d'une ville inconnue (corrélation prédit/réel de 0,62 à Tokyo à 0,90 à Barcelone) mais se trompe de niveau.
- **Latitude et longitude absolues sont des identifiants de ville déguisés** : retirer seulement les identifiants explicites (V2) dégrade la généralisation (0,676) ; retirer aussi les coordonnées (V3) revient à 0,594. Pour généraliser, il faut des variables géographiques relatives (distance au centre).
- **Schéma C** : avec toutes les variables, l'erreur sur les séjours d'octobre et après (0,391) est identique à celle du contrôle en septembre, mais elle augmente avec le mois (0,34 en octobre, environ 0,45 à partir de novembre) : les variables de date n'extrapolent pas à des saisons jamais vues.

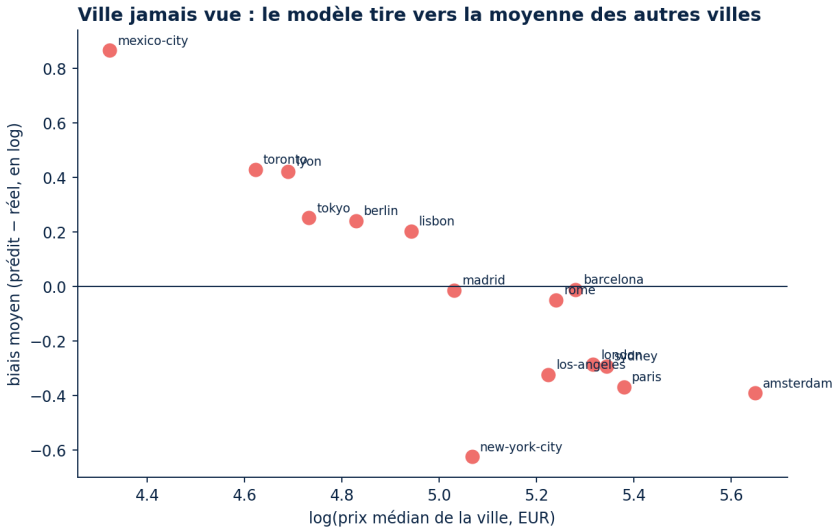


Figure 5. En ville inconnue, le biais est fortement lié au niveau de prix de la ville (corrélation -0,87) : Mexico est surestimée d'un facteur 2,4, New York et Amsterdam sont sous-estimées.

9 Régression du prix

Onze modèles et deux références naïves s'affrontent avec leurs réglages par défaut, en validation croisée à 5 plis groupés par hôte, sur les mêmes 80 000 annonces du train (un échantillon, pour que kNN, forêt aléatoire et Gradient Boosting restent praticables).

Modèle	RMSE (log)	R²	MAE (EUR)
Médiane de la ville	0,747	0,154	131
Régression linéaire	0,427	0,723	80
Ridge	0,428	0,722	80
kNN (k=15)	0,518	0,592	98
Arbre de décision	0,472	0,661	89
Random Forest	0,401	0,755	75
Gradient Boosting (sklearn)	0,386	0,774	72
HistGradientBoosting	0,380	0,781	71
XGBoost	0,374	0,787	70
LightGBM	0,375	0,786	70
Stacking (Ridge sur 5 modèles)	0,371	0,791	70

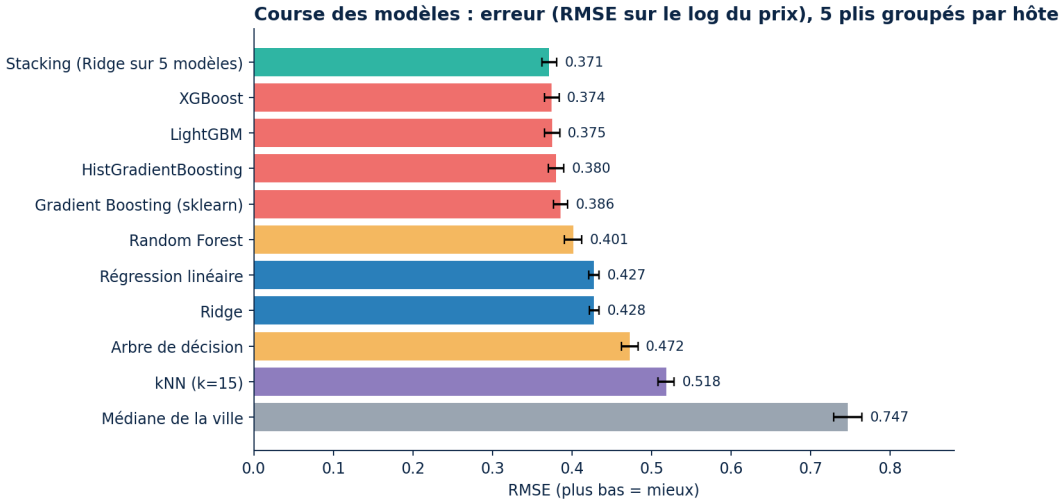


Figure 6. Course des modèles : le boosting domine, tous battent largement la médiane de la ville.

Constats

- **Le boosting domine** : XGBoost (0,374), LightGBM (0,375) et HistGradientBoosting (0,380), devant le Gradient Boosting de sklearn (0,386, mais 260 secondes par pli contre 7 pour LightGBM) et la forêt aléatoire (0,401).
- **Les modèles linéaires** donnent tous 0,428 et expliquent déjà 72 % de la variance avec une formule lisible. **Le kNN** est le pire modèle (0,518) : la malédiction de la dimension.
- **La médiane de la ville** (0,747, R² de 0,15) est la barre à franchir ; tous les modèles la battent largement.
- **L'empilement** (méta-modèle Ridge sur 5 modèles) gagne un peu (0,371) mais pèse presque uniquement XGBoost et LightGBM ; il n'a pas été reproduit sur le train complet réglé.

Réglage fin (Optuna)

Recherche bayésienne dans la validation croisée (3 plis groupés par hôte, 80 000 annonces), avec arrêt précoce des essais médiocres : **40 essais pour LightGBM** (RMSE 0,3699, 20 minutes) et **25 pour XGBoost** (0,3721). Le meilleur LightGBM a 873 arbres, un taux d'apprentissage de 0,04 et 149 feuilles. Sur les 309 412 annonces et 5 plis, le réglage fait passer le RMSE de 0,3654 à **0,3561** (−2,5 %) : les hyperparamètres affinent, ils ne bouleversent pas. Le modèle final est le LightGBM réglé (R^2 de 0,806 en validation croisée).

Retransformer en euros

Prédire le log du prix puis appliquer l'exponentielle donne l'estimation **médiane**, sous-estimée en moyenne. La correction de biais (smearing, facteur ≈ 1,09) corrige la moyenne mais **dégrade** l'erreur absolue moyenne (70 € contre 73 €), car la MAE est minimisée par la médiane. Le prix recommandé est donc l'estimation médiane ; le prix moyen corrigé est fourni à part.

Où le modèle se trompe

- **Par ville** : l'erreur absolue va de 32 € à Mexico à 91 € à Los Angeles, mais l'erreur relative médiane est homogène (de 17 % à 21 %).
- **Régression vers la moyenne** : les logements du décile de prix réel le plus bas sont surestimés de 21 %, ceux du plus haut sous-estimés de 47 %. La dispersion des résidus double dans le dernier décile (0,56 contre 0,26 à 0,32 ailleurs).
- **Par quart de prix réel (test)** : erreur moyenne de 17 € dans le quart le moins cher, de 182 € dans le plus cher.

10 Intervalles de prédiction et test final

Pour donner à l'hôte une fourchette plutôt qu'un point, trois méthodes sont comparées pour une couverture visée de 90 %, sur les prédictions hors échantillon (309 412 annonces). Pour le conformal, la marge de chaque pli est calibrée uniquement sur les résidus des autres plis.

Méthode	Couverture globale	Couverture minimale par décile de prix prédit	Largeur moyenne
Régression quantile	82,2 %	79,0 %	209 €
Conformal global	90,0 %	83,5 %	229 €
Conformal adaptatif (retenu)	90,0 %	89,9 %	243 €

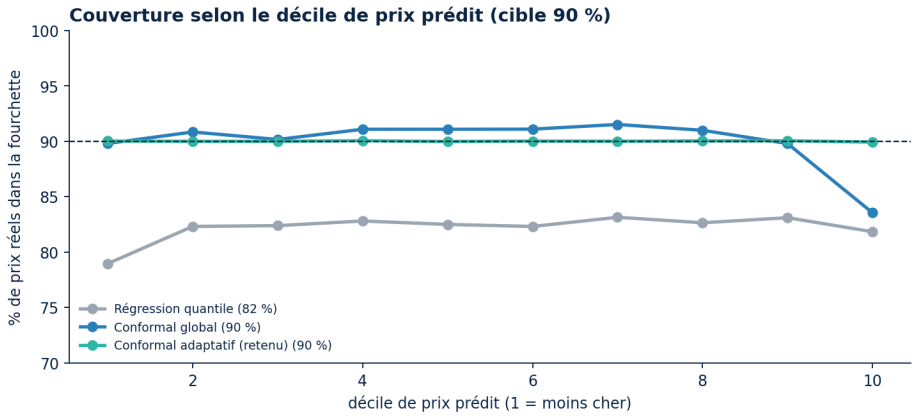


Figure 7. Couverture selon le décile de prix prédit : seule l'approche adaptative tient les 90 % partout.

- La **régression quantile** ne couvre que 82 % des prix réels : un modèle de quantiles entraîné sur les mêmes annonces que celles qu'il prédit est trop optimiste sur des hôtes nouveaux.
- Le **conformal global** atteint 90 % en moyenne mais descend à 83,5 % dans le décile de prix prédit le plus élevé (hétéroscédasticité).
- Le **conformal adaptatif (Mondrian)**, calibré par décile de prix prédit, couvre 90 % dans chacun des dix déciles pour une largeur supérieure de 6 %. C'est la méthode retenue.

Ouverture unique du jeu de test

Le jeu de test (69 304 annonces d'hôtes jamais vus, tiré avant toute exploration) est ouvert une seule fois, avec le modèle final ajusté sur tout le train. Le script refuse de s'exécuter une seconde fois.

Mesure	Validation croisée	TEST propre	TEST tous prix
RMSE (log)	0,356	0,354	0,372
R^2	0,806	0,815	0,802
MAE en euros	66	68	77
Erreur absolue médiane	27 €	27 €	27 €
Annonces à ±20 % du prix	53 %	53 %	53 %
Couverture de la fourchette à 90 %	90,0 %	90,4 %	90,3 %

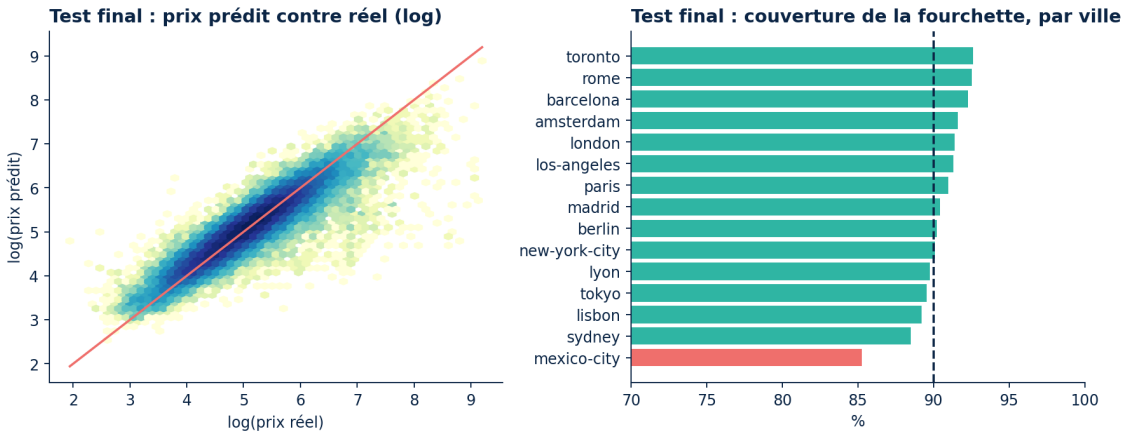


Figure 8. Test final : le prix prédit suit le prix réel ; la couverture est de 90 % en moyenne, avec Mexico à 85 %.

Le test confirme la validation croisée. RMSE 0,354 contre 0,356 (le modèle final est entraîné sur tout le train). **Nuance importante** : la garantie à 90 % porte sur le prix *prédit*, pas sur le prix réel : parmi les 2 949 annonces dont le prix réel dépasse 600 €, seules 68 % tombent dans la fourchette.

11 Classification

Deux tâches, même protocole (5 plis groupés par hôte sur 60 000 annonces du train). **Tâche 1** : l'hôte est-il Superhost ? (30 % de positifs.) **Tâche 2** : l'annonce est-elle dans la tranche de prix basse, moyenne ou haute de sa ville ? (terciles par ville, classes équilibrées.)

Superhost : la course des modèles (caractéristiques seules)

Modèle	ROC-AUC	PR-AUC	F1 (Superhost)	Temps par pli
Régression logistique	0,778	0,583	0,494	1 s
kNN (k=25)	0,749	0,531	0,354	3 s
SVM (RBF, 12 000 ex.)	0,772	0,579	0,493	179 s
Arbre de décision	0,758	0,539	0,491	2 s
Random Forest	0,800	0,620	0,495	7 s
HistGradientBoosting	0,813	0,634	0,556	13 s
LightGBM	0,817	0,637	0,561	4 s

Le boosting l'emporte (LightGBM : 0,817). L'accuracy est à interpréter avec prudence : un modèle répondant toujours « non Superhost » aurait 70 % d'accuracy ; les métriques utiles sont la PR-AUC (0,64 contre 0,30 pour le hasard) et le F1 de la classe rare.

Le test de la fuite : avec et sans notes et activité

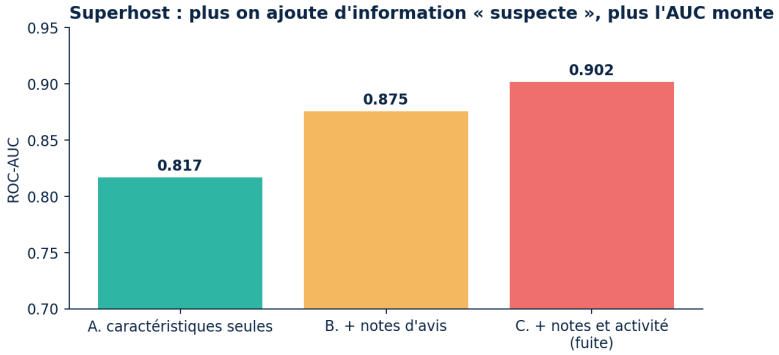


Figure 9. Plus on ajoute d'information issue des critères d'attribution, plus l'AUC monte.

Les notes d'avis font gagner 6 points d'AUC (0,817 → 0,875) et l'activité en gagne 3 de plus (0,902). Ces gains sont **trop beaux** : le statut est attribué d'après la note, la réactivité et le nombre de séjours. Deux usages, deux jeux de variables : **(A)** comprendre ce que le logement et l'hôte annoncent, sans circularité, utile pour repérer des hôtes à fort potentiel avant qu'ils n'aient des avis ; **(B)** reconstituer le statut avec les notes. Le jeu C (volume d'avis sur 12 mois) est une fuite et n'est pas retenu.

Déséquilibre des classes

Variante	Précision	Rappel	F1	ROC-AUC
LightGBM standard	0,721	0,620	0,666	0,875
LightGBM class_weight='balanced'	0,638	0,764	0,695	0,875
LightGBM + SMOTE	0,721	0,620	0,667	0,876
LightGBM seuil optimisé (F1)	0,626	0,776	0,693	0,875

Les trois traitements (poids de classe, SMOTE, seuil optimisé) ne changent pas l'AUC : ils déplacent le compromis précision/rappel. SMOTE n'apporte rien (variables mêlant comptages, binaires et encodages).

Poids de classe et seuil optimisé font passer le rappel de 62 % à environ 77 % au prix d'une précision de 63 %. Le modèle est bien calibré (écart maximal de 3,6 points entre probabilité annoncée et fréquence observée). En ville inconnue, l'AUC ne perd que 0,008 en moyenne (0,867 contre 0,859), sauf à Tokyo (0,838 → 0,789).

Tranche de prix

Modèle	Accuracy	F1 macro	AUC un-contre-tous
Régression logistique	0,704	0,705	0,869
kNN (k=25)	0,613	0,617	0,798
SVM (RBF, 12 000 ex.)	0,697	0,698	0,864
Arbre de décision	0,658	0,661	0,831
Random Forest	0,704	0,705	0,872
HistGradientBoosting	0,732	0,733	0,890
LightGBM	0,736	0,737	0,894

Les erreurs sont presque toutes entre classes voisines (1 % des annonces basses sont prédites hautes). En ville inconnue, l'accuracy moyenne passe de 0,73 à 0,65, avec de fortes disparités (New York tombe à 0,48 ; Lyon, Lisbonne et Madrid perdent 2 à 3 points).

Mesure	Validation croisée	Test final
Superhost, caractéristiques seules (AUC)	0,817	0,829
Superhost, avec les notes (AUC)	0,875	0,886
Tranche de prix (accuracy)	0,736	0,756
Tranche de prix (AUC un-contre-tous)	0,894	0,907

12 Apprentissage non supervisé

Pour que les groupes ne reproduisent pas les villes, les variables sont **relatives à la ville** (prix relatif à la médiane de la ville, rang de distance au centre). Échantillon : 60 000 annonces avec prix, 12 variables standardisées.

- **Peu de structure en groupes** : la silhouette est maximale à k = 2 (0,19) puis vaut 0,12 pour k ≥ 4, très loin du seuil de 0,25 d'une structure nette ; le coude est progressif ; le critère BIC d'un mélange gaussien préfère k = 9. Les annonces forment un continuum plus qu'un ensemble de familles.
- On retient **k = 5** (silhouette maximale parmi k ≥ 4) : un choix d'interprétabilité. Le hiérarchique (Ward) s'accorde partiellement avec k-means (ARI de 0,46), le mélange gaussien moins (0,29).
- **PCA** : la première composante (25,6 % de la variance) est un axe taille et standing (capacité, chambres, prix relatif) ; la deuxième (12,7 %) un axe maturité de l'annonce (avis, ancienneté de l'hôte) ; il faut 7 composantes pour 80 % de la variance.
- **DBSCAN** (rayon 150 m, 40 annonces minimum) trouve 48 zones denses à Paris et laisse 17,5 % d'annonces isolées ; le centre se fond en une zone géante par chaînage de densité (limite de l'algorithme).
- **Isolation Forest** : 1 % d'annonces atypiques, des propriétés de capacité médiane de 12 personnes, d'hôtes gérant environ 16 annonces ; atypique ne veut pas dire suspect.

Les cinq profils d'annonces

Profil	Part	Prix médian	Prix relatif	Capacité	Logements entiers	Annonces de l'hôte
grande capacité · prix élevés · logements entiers	13 %	392 €	×2,35	8	97 %	4
hôtes anciens · logements entiers · beaucoup d'avis	31 %	182 €	×1,12	4	98 %	4
logements entiers · peu d'avis · hôtes récents	30 %	159 €	×0,95	3	100 %	2
mal notés · peu d'avis · hôtes multi-annonces	2 %	134 €	×0,80	3	65 %	12
chambres chez l'habitant · prix bas · peu équipés	24 %	87 €	×0,54	2	0 %	4

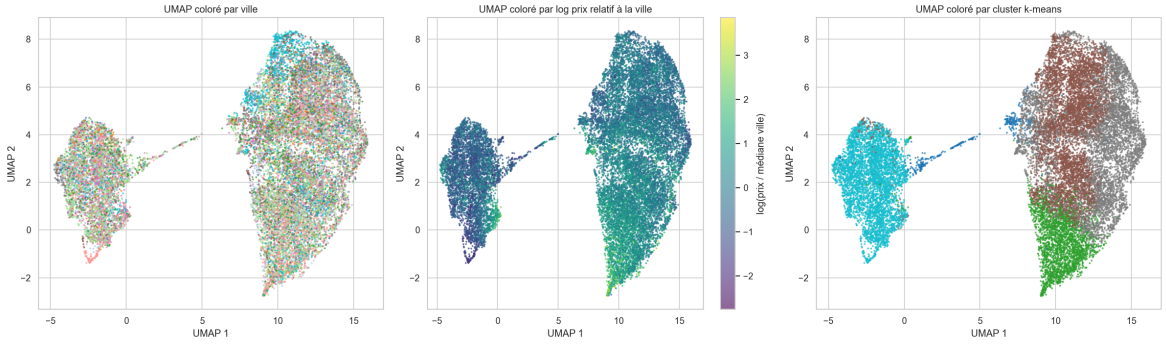


Figure 10. UMAP de 20 000 annonces : deux blocs (chambres chez l'habitant, logements entiers) ; les villes sont totalement mélangées, preuve que les variables relatives retirent bien l'effet ville.

Les cinq profils existent dans toutes les villes, dans des proportions différentes (New York compte 42 % de « chambres chez l'habitant », Paris 12 %). Un petit groupe de 2 % rassemble des annonces mal notées (note médiane 3,0) d'hôtes multi-annonces (12 en médiane) : un segment à surveiller pour la plateforme. Les noms sont déduits automatiquement des trois caractéristiques les plus écartées de la médiane globale.

13 NLP sur les avis

Échantillon (explicite) : 8 100 annonces du train (au moins 8 avis, 540 par ville au plus) et leurs 8 avis les plus récents, soit 64 528 avis. Ce choix favorise les annonces bien documentées. Tout ce qui apprend sur le texte (TF-IDF, LDA, PCA des embeddings) est ajusté dans chaque pli, sur les annonces d'entraînement.

- **Langues** : 60,6 % des avis sont en anglais, 12 % en espagnol, 11 % en français, 5 % en allemand ; un lexique anglais seul ignorerait près de 40 % des avis.
- **Sentiment** : modèle multilingue pré-entraîné (DistilBERT, *lxyuan/distilbert-base-multilingual-cased-sentiments-student*). Seulement 6,2 % d'avis négatifs (biais de positivité) ; le sentiment moyen d'une annonce est corrélé à sa note (Spearman 0,50). Les écarts entre langues reflètent probablement des styles d'expression, pas des niveaux de satisfaction.
- **Thèmes (LDA, 8 thèmes)** : le plus fréquent est « propreté, confort et réactivité » (22 % des avis, 0,3 % de négatifs). Les thèmes reprochés sont les avis nuancés (24 % de négatifs) et les défauts concrets du logement (cuisine, salle de bain, escaliers).

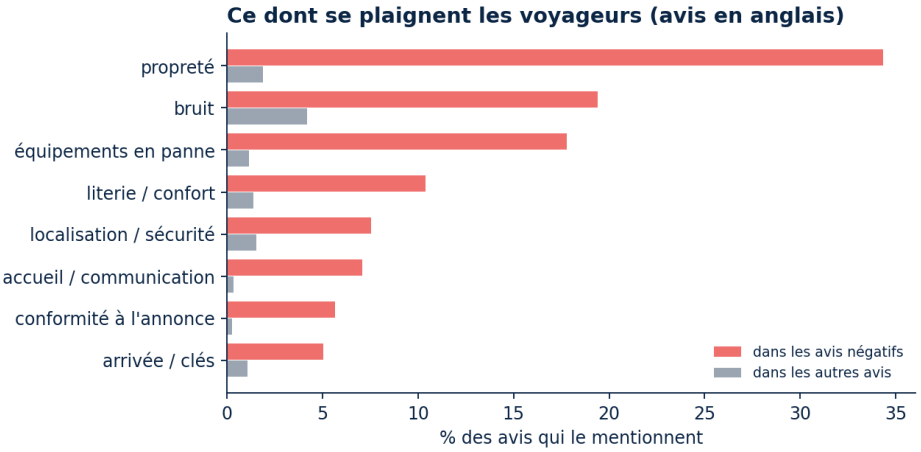


Figure 11. Points de friction : la propreté domine (34 % des avis négatifs en anglais, 18 fois plus que dans les autres avis).

Le texte améliore-t-il la prédiction ?

Tâche	Sans texte	Avec tout le texte	Lecture
Prix (RMSE du log, plus bas = mieux)	0,3387	0,3382	Aucun gain (écart inférieur au bruit entre plis)
Superhost sans les notes (AUC)	0,735	0,774	+0,04 : le texte remplace les notes absentes
Superhost avec les notes (AUC)	0,829	0,829	Aucun gain : le texte recopie la note

TF-IDF contre embeddings (texte seul) : équivalents pour la note et le Superhost ; TF-IDF est nettement meilleur pour le prix (RMSE 0,480 contre 0,513), probablement parce que les mots précis (noms de quartiers) portent une information géographique que la moyenne d'un embedding lisse. **Limites** : échantillon d'annonces bien documentées, langues minoritaires mal couvertes, biais de positivité, lexique de friction limité à l'anglais.

14 Séries temporelles (calendrier)

Les calendriers des 15 villes donnent la disponibilité des 365 prochaines nuits. **Deux limites** : le calendrier 2026 ne contient **pas de prix** (la série étudiée est la part de nuits indisponibles des annonces actives, un proxy de la demande) ; c'est un **instantané unique**, où l'effet d'horizon (les réservations s'accumulent à l'approche de la date) est mélangé à la saisonnalité annuelle.

- **Annonces bloquées en permanence** : 33 % à Paris, 40 % à Amsterdam, 39 % à Lyon, contre 3 % à Tokyo.
- **Courbe en U selon l'horizon** : la part de nuits indisponibles est élevée à court terme (48 à 81 %), minimale vers six mois (21 à 48 %), puis remonte (37 à 62 %), probablement parce que beaucoup d'hôtes n'ont pas encore ouvert leur calendrier lointain.
- **Saisonnalité hebdomadaire** : les nuits de vendredi et samedi sont les plus demandées, mais très inégalement (écart de week-end de +3,4 points à Madrid, +0,4 à Paris, où le pic est le jeudi).
- **Événements** : la Saint-Sylvestre ressort parmi les quatre plus forts pics dans 8 villes sur 15 ; Thanksgiving à Los Angeles et New York ; le Jour des morts à Mexico (+15 à +24 points).

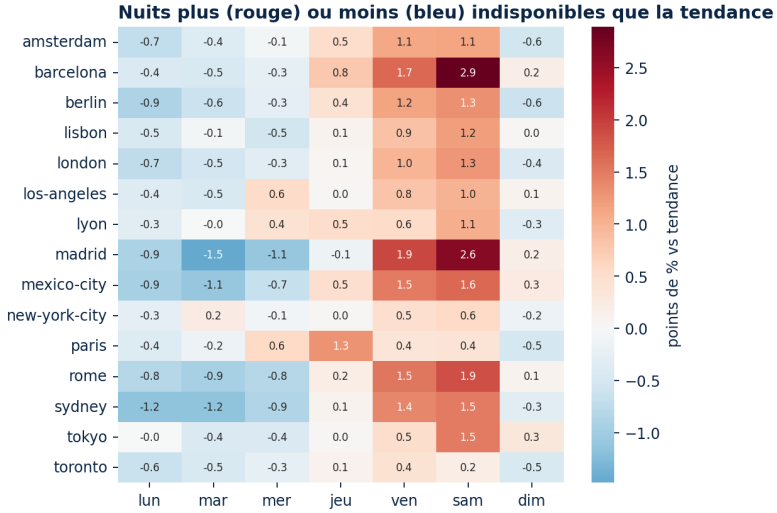


Figure 12. Profil hebdomadaire : nuits plus (rouge) ou moins (bleu) indisponibles que la tendance.

Prévision à 28 jours

Fenêtre glissante à origine mobile : 5 origines, 28 jours prévus, 15 villes. Modèles : baseline naïve saisonnière (la dernière semaine répétée), ETS, SARIMA, LightGBM global à variables calendaires (jours fériés du pays, jour de la semaine, horizon).

Modèle	MAE (points de %)
Naïf saisonnier (semaine précédente)	1,56
LightGBM global (calendrier + niveau récent)	1,66
ETS (tendance amortie + saison. hebdo)	2,12
SARIMA(1,1,1)(1,0,1,7)	2,31

Aucun modèle ne bat la baseline naïve en moyenne : à 28 jours, la série est dominée par un niveau lisse et une saisonnalité hebdomadaire très régulière, que la dernière semaine capte déjà. LightGBM la bat dans 4 villes sur 15. Il faudrait plusieurs instantanés pour faire mieux. **Apport métier** : les nuits de vendredi-samedi et les pics de fin d'année sont les moments où un prix plus élevé a le plus de chances de tenir ; attention, ces conclusions portent sur la disponibilité, pas sur le prix payé.

15 Deep learning

Réseau dense PyTorch (CPU) : couches d'**embeddings** pour les catégories (type de logement, type de propriété, ville, quartier), variables numériques imputées par ville puis standardisées, BatchNorm, dropout, AdamW, arrêt précoce sur 12 % des hôtes du train de chaque pli. Comparaison honnête avec LightGBM : mêmes 80 000 annonces, mêmes 5 plis, réglage Optuna des deux (20 essais pour le réseau, 40 pour LightGBM).

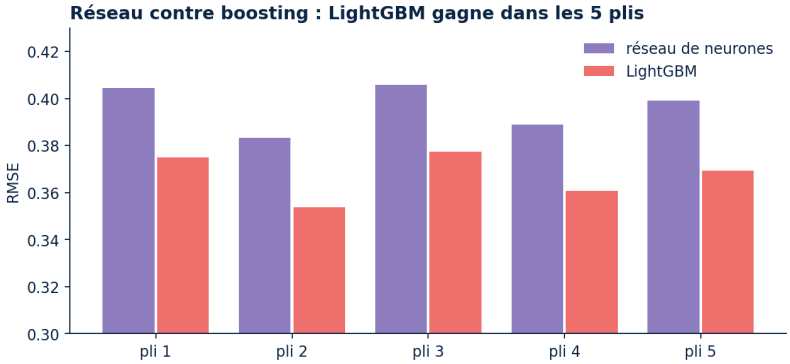


Figure 13. LightGBM est meilleur dans chacun des 5 plis.

Modèle	RMSE (log)	Budget de réglage
Réseau dense à embeddings	0,3965	20 essais, 82 min
LightGBM réglé	0,3674	40 essais, 20 min
Moyenne des deux	0,3712	—

Le boosting gagne, nettement et partout : 8 % d'erreur en moins, dans les 5 plis, les 15 villes et les 10 déciles de prix. Le réglage du réseau ne comble pas l'écart (RMSE de 0,401 à 0,413 selon les essais). La moyenne des deux est moins bonne que LightGBM seul : leurs erreurs sont très corrélées (0,89). Explications générales de la littérature (non testées une à une ici) : variables hétérogènes avec seuils nets, nombreuses variables peu informatives (164 équipements), invariance des arbres à l'échelle, taille de données modeste, coût de réglage.

16 Interprétabilité

Le modèle final est interprété avec **SHAP** (contribution de chaque variable à chaque prédiction) sur 22 500 annonces du train (1 500 par ville), puis avec des dépendances partielles. **Toutes les explications sont des associations apprises, pas des effets causaux.**

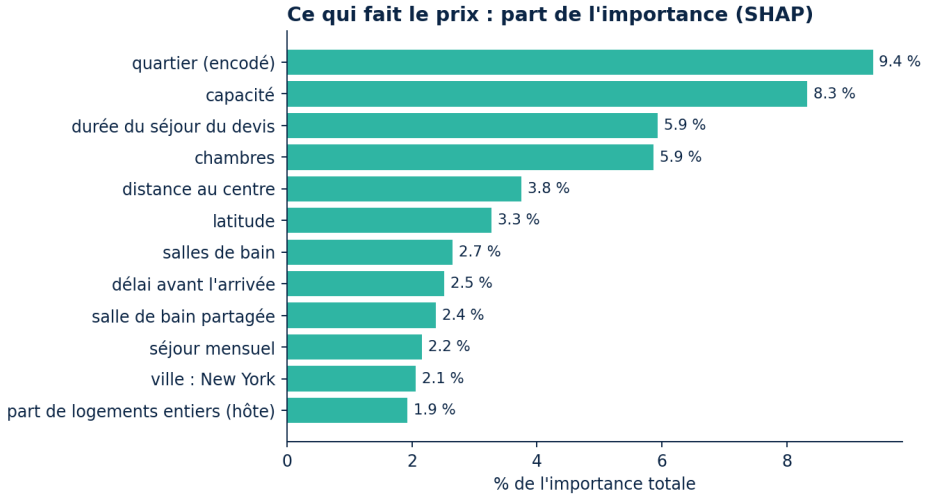


Figure 14. Importance globale (SHAP) : le quartier, la capacité, la durée du séjour et les chambres dominent.

Le contexte du devis (durée, délai, séjour mensuel) pèse 12,6 % au total, presque autant que la capacité et les chambres réunies (14,2 %). La ville n'apparaît qu'en 11e position (2,1 %) : le niveau local est déjà capté par le quartier.

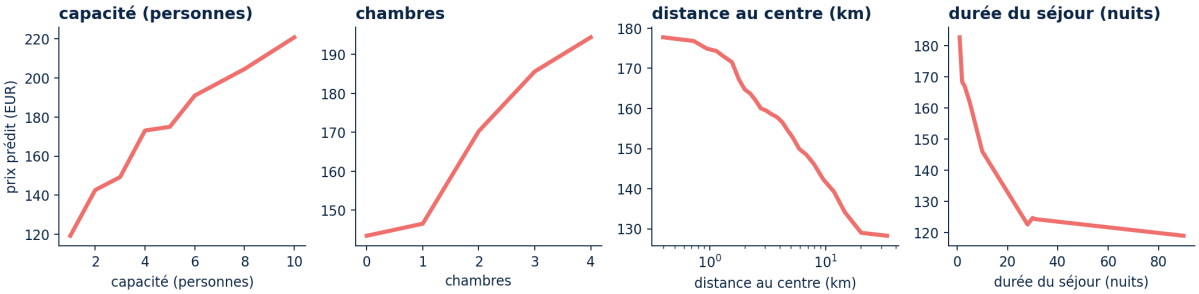


Figure 15. Dépendance partielle : effet moyen d'une variable, toutes choses égales par ailleurs.

Le prix moyen prédit passe de 119 € à 221 € quand on passe de 1 à 10 personnes, de 143 € à 194 € de 0 à 4 chambres, et baisse de 178 € à 128 € entre 0,4 km et 34 km du centre. **La durée du séjour a l'effet le plus fort** : de 183 € la nuit pour 1 nuit à 119 € pour 90 nuits (−35 %).

Trois annonces expliquées

Trois annonces parisiennes du test : une bon marché (réel 58 €, prédit 49 €, fourchette 29 – 82 €), une moyenne (réel 162 €, prédit 136 €, fourchette 83 – 223 €) et un cas de luxe (réel **839 €**, prédit **203 €**, fourchette 125 – 331 €). Le luxe illustre la sous-estimation des logements très chers : ce qui justifie ce prix (vue, standing, photos) n'est pas dans les données.

Les facteurs de prix sont presque les mêmes d'une ville à l'autre : la corrélation des classements d'importance entre villes est de 0,96 en moyenne (0,94 entre Paris et Tokyo). Les différences portent sur les proportions : le quartier pèse 17,5 % à Mexico et 15,1 % à Amsterdam contre 4,9 % à Lisbonne ; la durée du séjour 9 à 10 % à Toronto et Barcelone contre 3 % à Mexico et Amsterdam ; New York est la seule ville où l'indicateur de ville compte (13 %). Limite : ces parts viennent d'un seul modèle global.

17 Apport métier

Pour les hôtes

Le prix recommandé est l'estimation médiane du modèle, accompagné d'une fourchette à 90 %. Pour chaque équipement, on l'ajoute dans les données à 2 500 annonces qui ne l'ont pas et on mesure la variation du prix prédit.

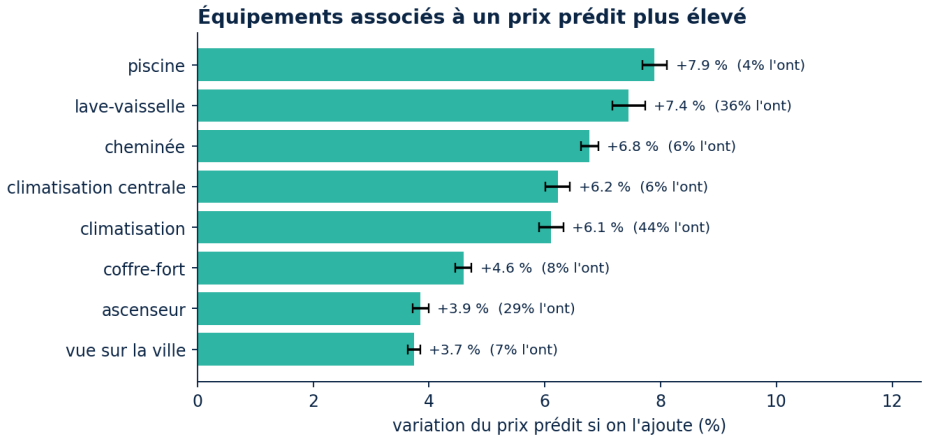


Figure 16. Équipements associés à la plus forte hausse du prix prédit (part des annonces qui l'ont déjà entre parenthèses).

- Les leviers **accessibles** sont ceux que beaucoup de logements n'ont pas : la **climatisation** (+6,1 % ; 44 % des annonces l'ont) et le **lave-vaisselle** (+7,4 % ; 36 %). Piscine (+7,9 %) et cheminée (+6,8 %) signalent plutôt un autre type de bien.
- Certains équipements sont associés à une **baisse** : le verrou de porte de chambre (−7,3 %, marqueur de chambres chez l'habitant), l'eau chaude (−3,9 %) ou le micro-ondes (−3,1 %), équipements presque universels que le modèle semble utiliser comme marqueur de logement standard. C'est la meilleure illustration de la différence entre association et causalité.
- **Durée et jours de séjour** : −35 % de prix par nuit entre 1 et 90 nuits ; les nuits de vendredi-samedi sont les plus demandées dans la plupart des villes.

Pour la plateforme

- **Annonces fantômes** : 15 % des annonces (indisponibles toute l'année, sans avis récent), de 1 % à Tokyo à 33 % à Lyon.
- **Annonces très écartées du prix attendu** : de 8 % (Rome) à 15 % (Mexico) des annonces sont à plus de 65 % au-dessus ou 39 % en dessous du prix prédit. Les sur-évaluées sont disponibles 247 jours par an contre 215 pour les annonces dans la norme : un signal de surveillance, par exemple un conseil de prix.
- **Points de friction** : la propreté (34 % des avis négatifs), le bruit (19 %), les équipements en panne (18 %). L'accueil et la conformité à l'annonce sont rares mais presque exclusifs des mauvais avis.
- **Profil du Superhost** : 41 avis en médiane contre 6, 14 avis sur 12 mois contre 0, note de 4,90 contre 4,78, 38 équipements contre 27 ; l'ancienneté est identique (5,6 ans).

Pour les investisseurs et les villes

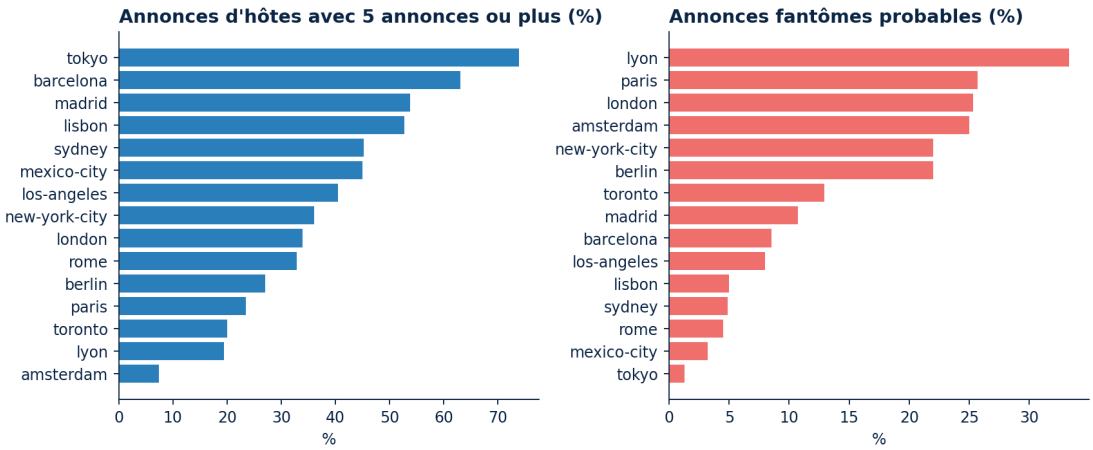


Figure 17. Concentration des hôtes professionnels et annonces fantômes, par ville.

- **Concentration** : de 7 % d'annonces d'hôtes à 5 annonces ou plus à Amsterdam à 74 % à Tokyo ; à Barcelone, les 10 % d'hôtes les plus gros détiennent 59 % des annonces.
- **Quartiers** : 160 quartiers sur 693 ont un écart significatif entre prix observé et prix attendu (sous-évalués : Edenbridge-Humber Valley à Toronto -26 %, Ribamar -18 % ; sur-évalués : Sant Andreu +25 %). Ce sont des pistes à vérifier, pas des recommandations d'achat.
- **Régulation** : la colonne de licence n'est pas renseignée à Londres et à Mexico.

Une ville jamais vue : que faut-il recalibrer ?

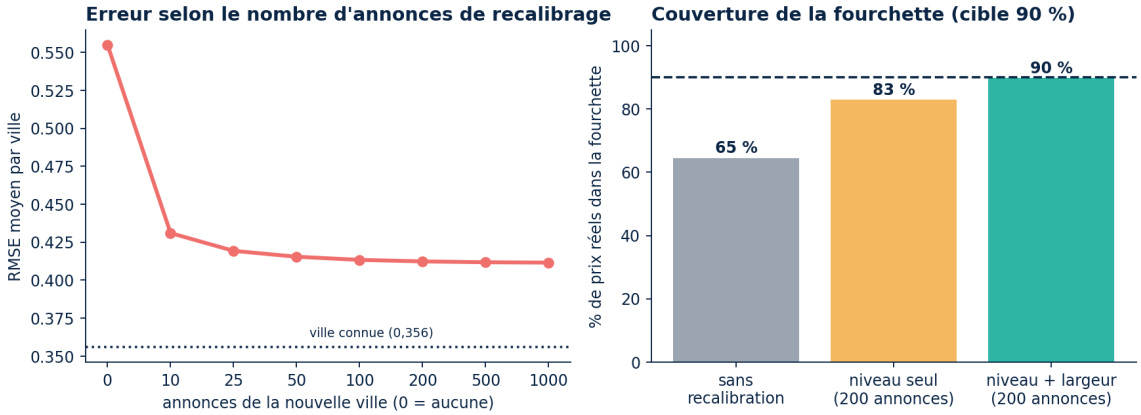


Figure 18. Recalibrer le niveau de prix avec quelques annonces suffit à corriger l'essentiel de l'erreur ; recalibrer aussi la largeur de l'intervalle rétablit la couverture de 90 %.

Sans recalibration, le RMSE moyen par ville est de 0,555 et la fourchette ne contient le prix réel que dans 65 % des cas. Avec **25 annonces** de la nouvelle ville, le RMSE tombe à 0,419 ; avec 200, à 0,412. Un simple décalage de niveau donne 83 % de couverture ; **niveau et largeur estimés sur 100 à 200 annonces ramènent la couverture à 90 %**.

- Niveau de prix : prix moyen observé moins prix moyen prédit sur 25 à 100 annonces.
- Largeur de l'intervalle : quantile à 90 % des résidus absolus sur 100 à 200 annonces, après correction du niveau.
- Devise : taux BCE à la date de collecte. Références géographiques : centre-ville et table des quartiers. À vérifier : vocabulaire d'équipements locaux et tranches de prix.

18 Limites et éthique

Limites des données

- Le prix est un **devis pour un séjour précis**, pas un prix payé ; aucune donnée de réservation réelle.
- **Biais de sélection** : le prix manque pour 25 % des annonces, surtout indisponibles ou non rafraîchies.
- Une seule collecte par ville : pas de mesure de dérive, pas de saisonnalité annuelle isolable ; le calendrier ne contient pas de prix.
- Variables absentes qui font le prix du luxe : photos, vue, surface, rénovation.
- Échantillons : sélection de variables sur 60 000 annonces, course des modèles sur 80 000, NLP sur 8 100 annonces bien documentées.

Limites du modèle

- Régression vers la moyenne : surestimation des logements bon marché, sous-estimation des plus chers ; couverture de la fourchette de 74 % dans le décile de prix réel le plus élevé.
- Ville inconnue : sans recalibration, l'erreur passe de 0,36 à 0,56 et la fourchette ne couvre que 65 % des prix.
- Associations et non causalité : le simulateur décrit ce que le modèle a appris.
- Types de logement rares moins bien couverts : 75 % pour les chambres d'hôtel, 80 % pour les chambres partagées.

Risques éthiques et réglementaires

- **Données personnelles (RGPD)** : le nom des hôtes est retiré, la licence réduite à un indicateur, les identifiants d'hôte ne servent qu'à grouper les validations, les avis sont agrégés.
- **Logement local** : recommander des prix peut encourager la conversion de logements en meublés touristiques, dans des marchés déjà très professionnalisés.
- **Homogénéisation des prix et coordination algorithmique** : si tous les hôtes suivent le même outil, les prix convergent. L'outil doit rester une aide à la décision avec fourchette, jamais un prix imposé.
- **Évolutions réglementaires** : licences et plafonds varient selon la ville et changent vite.
- **Biais de langue du NLP** : 60 % des avis sont en anglais, langues minoritaires mal couvertes.

19 Conclusion et recommandations

Le projet montre qu'il est possible d'estimer le prix d'un logement Airbnb avec une erreur médiane de 27 € par nuit et une fourchette qui tient ses promesses (90,4 % de couverture sur des hôtes jamais vus), tout en étant honnête sur ce que le modèle ne sait pas faire : le luxe, les villes nouvelles sans recalibration, la causalité.

#	Pour qui	Action	Résultat chiffré qui la justifie
1	Hôtes	Publier la fourchette à 90 % et pas seulement le prix	90,4 % de couverture sur le test ; 53 % à ±20 % ; erreur médiane 27 €
2	Hôtes	Ajuster selon la durée du séjour et les jours demandés	−35 % de prix par nuit entre 1 et 90 nuits ; week-end jusqu'à +3,4 points d'indisponibilité (Madrid) ; pics du 29 au 31 décembre dans 8 villes
3	Plateforme	Signaler les annonces très écartées du prix attendu et peu réservées ; traiter les fantômes	Sur-évaluées : 247 jours disponibles contre 215 ; 15 % de fantômes probables (33 % à Lyon)
4	Villes	Cibler la régulation sur la concentration et renseigner les licences	74 % d'annonces d'hôtes à 5 annonces ou plus à Tokyo, 59 % pour les 10 % d'hôtes les plus gros à Barcelone ; licences absentes à Londres et Mexico
5	Déploiement	Ne jamais déployer dans une nouvelle ville sans recalibrer	RMSE 0,555 → 0,419 avec 25 annonces ; couverture 65 % → 90 % avec niveau et largeur sur 100 à 200 annonces

Pistes d'amélioration

- Plusieurs collectes pour mesurer la dérive et la saisonnalité ; données de réservation ; photos et surface.
- Modèle par ville ou hiérarchique ; HDBSCAN pour les zones denses ; recherche d'hyperparamètres plus longue.
- Analyse causale (expériences de prix) pour passer des associations aux effets.

A Glossaire

Terme	Définition
RMSE, MAE	Erreur quadratique moyenne (racine) et erreur absolue moyenne. Sur le log du prix, une erreur de 0,37 correspond à un facteur d'environ ×1,45 ou ×0,69.
R^2	Part de la variance du prix expliquée par le modèle (1 = parfait, 0 = aussi bon que la moyenne).
Validation croisée groupée	Découpage en plis où un même hôte n'est jamais à la fois dans l'apprentissage et dans la validation.
Leave-one-city-out	On entraîne sur 14 villes et on teste sur la 15e, pour mesurer la généralisation à une ville inconnue.
Fuite de données	Information indisponible au moment de la prédiction, ou conséquence de la cible, qui rend un score artificiellement bon.
Target encoding	Remplacement d'une catégorie (le quartier) par la moyenne de la cible dans cette catégorie, calculée sans que l'exemple voie sa propre valeur.
SHAP	Mesure de la contribution de chaque variable à une prédiction donnée (valeurs de Shapley).
PDP / ICE	Courbes montrant comment la prédiction varie quand une variable change, en moyenne (PDP) ou pour des annonces individuelles (ICE).
Intervalle conforme	Fourchette dont la couverture est garantie sous des hypothèses d'échangeabilité ; la version adaptative (Mondrian) calibre la marge par tranche de prix prédit.
ROC-AUC, PR-AUC	Qualité du classement des cas positifs ; la PR-AUC est plus informative quand la classe positive est rare.
Silhouette	Mesure de la netteté de groupes (de −1 à 1) ; au-dessus de 0,25 on parle de structure nette.
Optuna	Bibliothèque de recherche bayésienne d'hyperparamètres avec arrêt précoce des essais médiocres.

B Reproductibilité et décisions à justifier

Reproduire le projet

- Environnement : Python 3.14.3, versions figées dans *requirements.txt*, graine 42, configuration unique *config.yaml*.
- *python run_all.py* exécute l'ensemble (plusieurs heures sur 16 cœurs ; les étapes lourdes sont mises en cache). Le jeu de test n'est ouvert qu'une fois par *src/final_model.py*.
- Le notebook *00_projet_complet.ipynb* contient le code de chaque module à la fin du chapitre concerné, les graphiques et les interprétations. *python predict.py* donne un exemple d'utilisation du modèle.

Décisions à justifier

Décision	Justification
Prédire le log du prix	Distribution écrasée (asymétrie 57 → 0,6) ; erreurs relatives plutôt qu'absolues
Découpage par hôte	253 996 hôtes pour 485 128 annonces ; un découpage par annonce ferait fuiter l'hôte
Contexte du devis comme variables	Le prix est un devis de 1 à 31 nuits ; RMSE 0,396 → 0,374
Exclure disponibilités et avis récents	Conséquences du prix ; le jeu complet est meilleur mais inutilisable par un hôte qui fixe son prix
Taux BCE à la date de collecte	Le « $ » du brut est trompeur ; taux sourcés et reproductibles
Target encoding à validation croisée interne	1 294 couples ville-quartier ; l'encodage naïf triche
Boosting	0,375 contre 0,428 pour le linéaire ; le réseau de neurones ne le bat pas
MAE sans correction de biais	La correction corrige la moyenne mais dégrade la MAE (70 → 74 €)
Conformal adaptatif	Quantile : 82 % ; global : 83,5 % dans le dernier décile ; adaptatif : 90 % partout
Deux schémas de validation	RMSE 0,366 (ville connue) contre 0,583 (ville inconnue)
Deux usages du Superhost	Avec les notes, on lit en partie les critères d'attribution (0,875) ; sans, on mesure ce que l'annonce annonce (0,817)
Aucune ligne supprimée	Les cas douteux sont signalés ; on peut mesurer ce que le filtrage change